

2-Stage CatBoost를 활용한 열수요 예측 모델 개발

Heat Demand Forecasting via a Two-Stage CatBoost Modeling Approach

참가팀명 : 따숨조

접수번호 : 250241

본 연구는 CatBoost 기반의 2-Stage 열수요 예측 모델을 제안한다. 1차 모델에서 예측된 수요와 실제 관측값 간의 오차를 별도의 보정 모델로 학습함으로써 예측 성능을 향상시키고자 하였다. 외기 온도, 기상 정보, 과거 데이터를 입력 변수로 활용하였으며, 제안된 모델은 계절 변화와 수요 패턴의 비선형성에 유연하게 대응할 수 있다. 이를 통해 지역난방 시스템의 안정적이고 효율적인 운영에 기여할 수 있을 것으로 기대된다.

중심어: CatBoost, 2-Stage, 비선형성, 계절 변화

1장. 서론

지역난방은 대규모 열 생산 시설에서 여러 건물에 열을 공급하는 고효율·친환경 난방 방식으로, 에너지 절약과 온실가스 저감이라는 두 가지 목표를 동시에 달성할 수 있는 수단으로 주목받고 있다. 최근에는 탄소중립 실현과 스마트 에너지 시스템 구축을 위한 핵심 기반으로서의 중요성이 더욱 커지고 있으며, 특히 열 생산과 공급의 안정성과 효율성을 확보하기 위해 정확한 열수요 예측이 필수적이다. 열수요는 외기 온도, 일조량, 풍속과 같은 기상 변수뿐만 아니라 요일, 계절, 사용자 행동 등의 사회문화적 요인에 의해 복합적으로 영향을 받는다.


이에 따라 기존 연구에서는 다중회귀모형, 시계열 분석, 칼만 필터, ANN, RNN, LSTM 등 다양한 통계 및 기계학습 기법을 활용해 왔다. 회귀모형은 해석이 용이하다는 장점이 있으나 복잡한 비선형 관계를 반영하는 데는 한계가 있으며, 딥러닝 기반 모델은 복잡한 패턴 학습에 강점을 가지는 반면, 해석력과 학습 효율성에서 제약이 존재한다. 본 보고서에서는 이러한 다양한 예측기법과 변수들을 종합적으로 검토하고 실증 실험을 통해 비교함으로써, 실제 지역난방 운영에 효과적으로 적용 가능한 현실적이고 범용적인 예측모형 개발을 위한 기반을 제시하고자 한다.

2장. 데이터 구성 및 전처리

본 장에서는 train_heat.csv와 test_heat.csv를 기반으로 모델 개발을 위한 분석을 수행한다. 먼저 train 데이터를 활용해 데이터 구조를 파악하고, 예측 성능 향상을 위한 EDA, 전처리, 파생 변수 생성 과정을 진행한다. test 데이터는 최종 예측 결과 도출에 활용되며, 각 절에서는 데이터 탐색부터 정제, 특성 공학까지의 절차를 구체적으로 설명한다.


2-1. EDA

그림은 heat demand(열수요), ta(대기온도), rn_hr1(1시간 강수량), ws(풍속)에 대한 시간에 따른 변화를 나타낸 플롯이다.




[그림 1. heat demand EDA]

가장 먼저 heat demand는 뚜렷한 계절성을 보이며, 겨울철에 급격히 증가하고 여름철에는 낮은 수준을 유지하는 전형적인 계절적 패턴을 나타냈다. 또한, branch_id(지사)별로 열수요의 절대 수준과 변화 양상에 차이가 존재함을 확인할 수 있다.



[그림 2. ta, ta_chi EDA]

기상 변수 중 ta(대기온도)계절에 따라 여름철에 높고 겨울철에 낮은 뚜렷한 주기적 변화를 보였으며, ta_chi(체감온도), si(일사량) 역시 유사한 계절성을 나타냈다.



[그림 3. rn_hr1, ws EDA]

rn_hr1(1시간 강수량)은 비교적 낮은 수준에서 분포하면서도 계절에 따라 점진적인 변화 양상을 보였고, ws(풍속)는 다른 변수들과는 달리 명확한 계절성 없이 불규칙하고 랜덤한 패턴이 보인다.

2-2. 전처리

EDA 결과에 따라 결측치 모완 전략을 세 가지로 분류하였다. ta, hm, ta_chi, si는 뚜렷한 시계열성을 보여, 임시 변수(hour, dayofweek, dayofyear, month)의 주기성을 반영한 sin, cos 파생변수를 적용하고 남은 결측치는 RandomForest로 보완한다.

- si: 일출·일몰 전후 1시간대 결측치는 계절별 기준에 따라 0으로 처리
- ta_chi: 여름철(5~9월)과 겨울철(10~익년 4월) 체감온도 수식을 통해 보완
- ta: 체감온도 수식 역추정을 통해 보완

rn_hr1과 rn_day는 ta, hm, si, branch_id를 활용해 RandomForest로 남은 결측치를 보완하고 wd와 ws는 뚜렷한 추세가 없어 ffill 방식으로 처리하였다.

2-3. 파생변수

본 연구에서는 열수요 예측의 정확도를 높이기 위해 시간, 기상, 사회적 요인을 반영한 다양한 파생 변수를 생성한다. 시간 기반 변수로는 월, 요일, 시간 및 주기형 변환, 주말 여부, 계절 구분을 포함한다. 공휴일과 코로나 시기는 이진 변수로 정의하여 사회적 영향도 반영한다. 또한 체감온도와 실내 적정온도 가이드라인을 참고하여 정의한 쾌적온도 범위 간의 차이를 기반으로 Comfort Distance, Heating Degree Days, Cooling Degree Days 변수를 도출한다. 주요 기상 변수는 지점별 시계열 특성을 반영하기 위해 Lag 및 이동평균 변수로 확장하였으며, 시간 단위는 1~24시간, 2~4일, 1주, 2주, 1개월로 구성한다.

구분	변수명	설명
시간 기반	month, day_of_week, hour	관측시점의 월, 요일, 시각
	month_sin, month_cos, hour_sin, hour_cos	월, 시간 주기성 반영을 위한 사인/코사인 값
	weekend	주말 여부
	winter, summer	겨울(1, 2, 12월), 여름(6, 7, 8월) 여부
	is_holiday	공휴일 여부
공휴일 및 팬데믹	is_covid_period	코로나 시기 여부(2021.03.01. ~ 2022.06.30.)
쾌적온도 기반	comfort_distance	쾌적온도와 체감온도 간 최소 거리
	heating_degree_days, cooling_degree_days	난방이 필요한 정도(겨울 기준: 18~21°C), 냉방이 필요한 정도(여름 기준: 24~27°C)
시계열 기반	ta_chi_lag_k, hm_lag_k, si_lag_k	체감온도, 습도, 일사량의 과거 k시간 전 값
이동평균 기반	ta_chi_ma_k, si_ma_k	체감온도, 일사량의 과거 k시간 이동평균

[표 1. 파생변수 설명]

3장. 분석 방법

본 장에서는 열수요 예측을 위한 데이터 전처리, 피쳐 구성, 학습·검증 데이터 분할 및 모델링 기법에 대해 설명한다. 또한, 단일 모델 성능 비교와 더불어 예측 성능 향상을 위한 2-Stage 모델링 접근법을 다룬다.

3-1. 모델 입력 데이터 전처리 및 구성

본 연구에서는 모델 학습을 위한 Feature Matrix 생성을 위해 별도의 전처리 스케일링 프로세스를 구성한다. 특히 데이터 누수를 방지하기 위해 학습용과 테스트용 데이터를 명확히 분

리하여 동일한 절차를 적용한다.

모델 학습을 위한 Feature Matrix 생성을 위해 전처리, 피처 생성, 스케일링 등 일련의 전처리 과정을 설계한다. 시계열 기반의 Lag 피처 생성을 위해 테스트 데이터에는 예측 시점 이전 최소 720시간의 과거 데이터를 학습 데이터에서 추출해 앞단에 패딩 처리한다. 이후 학습, 테스트 데이터를 병합한 뒤, 시간, 기온, 쾌적도 등 다양한 파생 피처를 생성하고, branch_id는 Label Encoding을 적용한다. 수치형 변수는 Min-Max Scaling으로 정규화하여 스케일 편차를 보정하며, 스케일링 기준은 학습 데이터로부터 추정한다. 마지막으로 데이터 누수를 방지하기 위해 2021~2022년을 학습용으로, 2023년을 검증용으로 분할한다.

3-2. 단일 모델

대표적인 Gradient Boosting 계열 모델인 Catboost, XGBoost, LightGBM을 대상으로 성능 비교를 수행한다. 각 모델은 동일한 전처리, 스케일링, 피처 셋을 바탕으로 학습되었으며, 검증 데이터에서의 예측 성능을 바탕으로 비교한다.

사용모델	RMSE	사용모델	RMSE
CatBoost	15.1249	RNN	35.9074
XGBoost	17.4313	LSTM	15.8938
LigthGBM	17.5197		

[표 2. 단일 모델 RMSE 결과]

3-3. 2-stage 모델


복잡한 열수요 예측 문제에서 단일 모델이 전체 패턴을 포괄적으로 설명하는 데 한계가 있다. 이를 보완하기 위해, 본 연구에서는 2-Stage 모델링 기법을 적용한다. 해당 기법은 예측 대상을 두 단계에 걸쳐 순차적으로 모델링함으로써, 기본 예측값이 설명하지 못한 복잡한 잔차 패턴을 보정하는 과정을 포함한다.

3-3-1. Stage 1: 1차 예측 모델 학습

선정된 단일 모델로부터 학습, 검증 데이터에 대한 예측값을 생성하고, 실제값과의 차이인 잔차를 계산한다.

$$Residual = y - \hat{y}_{stage1}$$

아래 [그림 4]는 Stage1 모델의 잔차 플롯으로, 잔차가 단순한 랜덤 분포가 아닌 특정 구간에서 패턴이나 비선형적인 동향을 보임을 확인할 수 있다. 이와 같은 잔차의 체계적인 동향은 1차 모델이 데이터 내 일부 복잡한 패턴을 완전히 설명하지 못함을 시사한다.



[그림 4. 잔차 플롯]

이러한 잔차의 비정상적 동향을 보정하고 예측 성능을 개선하기 위해, 잔차의 별도의 목표 변수로 설정하여 2-Stage 모델링 기법을 적용한다.

3-3-2. Stage 2: 입력 구성 및 모델 학습

Stage 2에서는 Stage 1의 예측값을 새로운 입력 피처로 추가하여, 기존 피처 행렬에 결합한다. 즉, 입력 피처는 ‘기존 변수 + 1차 예측값’이며, 타깃은 Stage1의 잔차이다.

$$X_{stage2} = [X_{original}, \hat{y}_{stage1}]$$

CatBoost를 활용하여 잔차를 예측하는 Stage 2 모델을 학습한다. 이에 1단계에서 설명하지 못한 비선형적인 오차 패턴을 보정할 수 있도록 설계한다.

3-3-3. 최종 예측 및 성능 평가

검증 데이터에 대해 1단계 예측값과 2단계 잔차 보정값을 합산하여 최종 예측값을 생성한다.

$$\hat{y}_{final} = \hat{y}_{stage1} + \hat{r}_{stage2}$$

최종적으로 RMSE 지표를 통해 성능을 평가했으며, 단일 Stage 모델 대비 RMSE 감소를 통해 2-Stage 접근 방식의 효과를 확인할 수 있다.

사용모델(Stage1 + Stage2)	RMSE
CatBoost + CatBoost	14.7179
CatBoost + XGBoost	14.9249
CatBoost + LigthGBM	15.0650

[표 3. 2-stage model RMSE 결과]

4장. 결과 및 검증

4-1. 하이퍼파라미터 튜닝

모델의 성능을 극대화하기 위해 CatBoost 모델에 대한 하이퍼파라미터 튜닝을 수행한다. 본 연구에서는 탐색 효율성과 모델 일반화 성능을 동시에 고려하기 위해 Bayesian Optimization 기반 AutoML 기법을 활용한다. 이를 통해 반복적인 실험 없이도 최적의 파라미터 조합을 자동으로 탐색할 수 있도록 설정한다. 그 결과, 최적 파라미터 조합은 다음과 같다.

depth	learning_rate	l2_leaf_reg	iterations
11	0.03393210522320859	0.7175552747952061	1782

[표 4. 최종 하이퍼파라미터]

튜닝된 파라미터는 최종 Stage1 및 Stage2 CatBoost 모델 학습에 적용되어 예측 성능 향상에 기여한다.

4-2. 최종 모델 성능 및 검증

4-1장에서 도출한 최적 하이퍼파라미터 적용 결과, 6월 26일 기준 검증 RMSE는 13.17로 2-stage 대비 오차가 감소하며 안정적인 예측 성능을 확인했다.

사용 모델(Stage 1 + Stage2)	2-stage RMSE	검증 RMSE
CatBoost + CatBoost	13.9876	13.17

[표 5. 최종 모델 성능 결과]

5장. 활용 방안 및 향후 방향

본 연구에서 제안한 열수요 예측 모델은 대국민 생활 안정과 에너지 산업 효율화 측면 모두에 기여할 수 있다. 약 190만 세대에 이르는 전국적인 난방 수요를 정밀하게 예측함으로써, 기온 변화, 시간대, 공휴일, 사회적 이벤트(예: 코로나19)에 따른 수요 변동에 선제적으로 대응할 수 있으며, 이를 통해 열공급 중단 및 지역 간 온도 불균형 문제를 완화할 수 있다. 또한 약 4,800km에 달하는 열수송관망을 운영하는 한국지역난방공사의 입장에서는 본 모델을 활용해 발전소 가동 계획, 연료 조달, 설비 운영 등의 의사결정을 최적화할 수 있어, 산업 전반의 효율성과 안정성을 동시에 확보할 수 있다.

날짜 및 기상 변수 기반의 데이터를 활용하여 열수요 예측 모델을 구축하였으나, 지사별 인구 구성, 도시 구조, 지역 특성 등으로 인해 열수요 패턴의 차이가 존재할 수 있다. 이에 향후 연구에서는 인구통계, 공간정보 등 지역 맥락을 반영한 데이터를 추가하여 모델의 설명력과 현실 적합성을 높일 수 있을 것이다. 또한, 장기 예측을 위해서는 국내총생산, 가계소득, 지역 난방 요금 등 주요 경제 지표를 함께 고려하는 통합적 접근이 필요하다. 더 나아가, 전체 지사를 단일 모델로 예측하는 방식에서 벗어나, 지사 간 수요 특성 유사도를 클러스터링하고 특화된 모델을 구축함으로써 예측 정밀도를 높일 수 있다. 이는 실제 열공급 운영의 전략 수립 및 자원 배분 효율화에도 기여할 수 있을 것이다.

Reference

1. 송기범, 박진수, 김윤배, 정철우, 박찬민. (2011). 지역 난방을 위한 열 수요예측. *IE Interfaces*, 24(4), 373-378.
2. Chramcov, B., & Vařacha, P. (2012). Design of a model for heat demand prediction using the neural network synthesis. *Conference Paper*.
3. 서병선, 심상렬. (2012). 지역난방 열에너지 수요예측. *에너지경제연구*, 11(2), 27-55.
4. 김향민, 김태환, 김대욱. (2019). 열병합발전을 위한 열수요 예측모델 개발: 일산화력본부 자료를 중심으로. *한국데이터분석학회지*, 21(5), 2465-2478.
5. Catalina, T., Iordache, V., & Caracaleanu, B. (2013). Multiple regression model for fast prediction of the heating energy demand. *Energy and Buildings*, 57, 302-312.
6. Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735-1780.
7. Gers, F. A., Schmidhuber, J., & Cummins, F. (1999). Learning to forget: Continual prediction with LSTM. *Neural Computation*, 12(10), 2451-2471.